Numerik Boxen

Florian Lubitz & Steffen Hecht

28. März 2018

1 1

11

$$v + 134 = 16$$

12

$$f_{rd}(r) := \delta_r := rd(r) - r$$

13

$$f_{rel} := \epsilon_r := \frac{\delta_r}{r} = \frac{rd(r) - r}{r} \qquad \text{für} \qquad r \neq 0$$

16

$$|\delta_r| \leqslant 2^{e-t} \qquad \text{und} \qquad |\epsilon_r| \leqslant 2^{-t}$$

17

$$\epsilon = 2^{-t}$$

18 ...die entsprechenden Maschinenoperationen, d.h. die Anwendung der jeweiligen Operation auf Zahlen im normierten Gleitpunkzahlenformat nach Def. 1.2

19 I) Verknüpfung der Maschinenzahlen mit höherer (ausreichend hoher) Genauigkeit

II) Runden des Ergebnisses auf eine Maschinenzahl

20

$$20 r \circ_M s := rd(r \circ s)$$

21 21

$$\begin{aligned} r +_M s = (1,11)_2 \cdot 2^0 +_M (1,10)_2 \cdot 2^2 &= (111)_2 \cdot 2^{-2} + (1,10)_2 \cdot 2^{-2} \\ &= (1000,10)_2 \cdot 2^{-2} \\ &= (100010)_2 \cdot 2^1 \\ &= (1,00)_2 \cdot 2^1 = (2)_{10} \end{aligned}$$

wohingegen das exakte Ergebnis $r + s = \frac{7}{4} + \frac{3}{8} = \frac{17}{8}$ ist.

Der absolute Rundengsfehler

$$f_{rd} = (r +_M s) - (r + s) = 2 - \frac{1}{8}$$

und der relative Rundungsf

$$|f_{rel}| = |\frac{(1 +_M s) - (r + s)}{r + s}| = \frac{\frac{1}{8}}{\frac{17}{8}} = \frac{1}{17} = 0,0588...$$

DAs ist relativ gut, denn der maximale Rundugnfehler bei einer 3-stelligen Mantisse ist $\epsilon = 2^{-3} =$

22 23

$$r \circ_M s = rd(r \circ s) = (r \circ s) \cdot (1 + \epsilon_0)$$

wobei der realtie Fehler ϵ_0 der Gleitpunktoperation wegen Def. 1.10 stets durh die Maschinengenauigkeit beschränkt ist,

$$\epsilon_0 := \frac{(r \circ_M s) - (r \circ s)}{r \circ s} = \frac{rd(r \circ s) - (r \circ s)}{r \circ s} \leqslant \epsilon$$

23

$$\begin{aligned} 24\tilde{y} =& \tilde{x} +_M c \\ &= (\tilde{x} + c) \cdot (1 + \epsilon_2) \\ &= ((a +_M b) + c) \cdot (1 + \epsilon_2) \\ &= ((a + b) \cdot (1 + \epsilon_1) + c) \cdot (1 + \epsilon_2) \\ &= a + b + c + (a + b) \cdot \epsilon_1 + (a + b + c) \cdot \epsilon_2 + (a + b) \cdot \epsilon_1 \epsilon_2 \end{aligned}$$

24

$$25\tilde{y} \doteq a + b + c + (a + b) \cdot \epsilon_1 + (a + b + c) \cdot \epsilon_2$$

25

$$\begin{aligned} 26 f_{rel}(y) = \frac{\tilde{y} - y}{y} &= \frac{(a + b) \cdot \epsilon_1 + (a + b + c) \cdot \epsilon_2}{a + b + c} \\ &= \frac{a + b}{a + b + c} \cdot \epsilon_1 + \epsilon_2 \end{aligned}$$

26

$$27|f_{rel}(y)| = |\frac{a+b}{a+b+c} \cdot \epsilon_1 + \epsilon_2| \overset{(D.U.G)}{\leqslant} |\frac{a+b}{a+b+c}| \cdot |\epsilon_1| + |\epsilon_2|$$

27

$$28|f_{rel}(y)| \leqslant (1 + |\frac{a+b}{a+b+c}|) \cdot \epsilon = (a + \frac{1}{|1+\frac{c}{a+b}|}) \cdot \epsilon$$

28 29

$$c \approx -(a+b)$$

ist. Denn für $c \to -(a+b)$ ist $\frac{|a+b|}{|a+b+c|} \to \infty$ und damit wird auch die obere Schranke von $|f_{rel}(y)|$ beliebig (unendlich) groß. In diesem Fall spricht man von **Auslöschung**