Numerik Boxen

Florian Lubitz & Steffen Hecht

16. April 2018

1 1

1 Die Gleitpunktzahlendarstellung zerlegt jede reelle Zahl $r \in \mathbb{R}$ in drei Bestandteile:

I) ein Vorzeichen $(-1)^v$ mit $v \in \{0, 1\}$

II) eine Mantisse $m \in \mathbb{R}$ und

III) einen Exponenten $e \in \mathbb{Z}$, sodass

$$r = (-1)^v \cdot m \cdot 2^e \tag{1.1}$$

2

$$r = (-1)^v \cdot \sum_{i=0}^{t-1} r_i \cdot 2^{-i} \text{ mit } r_0 = 1 \text{ (sodass } 1 \leq m \leq 2) \tag{1.2}$$

3

$$\begin{aligned} 13,6 &= 2^3 + 5,6 \\ &= 2^3 + 2^2 + 1,6 \\ &= ... \\ &= 2^3 + 2^2 + 2^0 + 2^{-1} + 2^{-4} + 0,0375 \\ &= ... \end{aligned}$$

Also können wir die Dezimalzahl $(13,6)_{10}$ als Binärzahl $(1101,1001...)_2$ darstellen.

4

$$\begin{aligned}(13,6)_{10} &= (1101,1001...)_2\\ &= (-1)^0 \cdot (1,1011001...)_2 \cdot 2^3\end{aligned}$$

also $v = 0$, $m = (1,1011001...)_2$ und $e = 3$

5

Eine reelle Zahl $r \in \mathbb{R}$ mit der Darstellung

$$r = (-1)^v \cdot \sum_{i=0}^{t-1} r_i \cdot 2^{-i} \cdot 2^e \text{ mit } r_0 = 0 \tag{1.3}$$

gehört der Menge der nicht-normierten oder subnormalen Gleitpunktzahlen $\mathbb{M}_s$ an.

6

Es gilt analog zu Definition 1.2: Das Vorzeichen $(-1)^v$ wird durch das Vorzeichen-Bit $v \in \{0,1\}$, der Wert der Mantisse m durch die Ziffern $r_i \in \{0,1\}$, $i = 1,...,t-1$ und der Wert des Exponenten durch eine ganze Zahl $e \in \mathbb{Z}$ mit $e = e_{min}$ festgelegt.

7

$$0 = (-1)^v \cdot 0 \cdot 2^{e_{min}} \tag{1.4}$$

11

$$v + 134 = 16$$

12

$$f_{rd}(r) := \delta_r := rd(r) - r$$

$\boxed{13}$

$$f_{rel} := \epsilon_r := \frac{\delta_r}{r} = \frac{rd(r) - r}{r} \quad \text{für} \quad r \neq 0$$

$\boxed{16}$

$$|\delta_r| \leqslant 2^{e-t} \qquad \text{und} \qquad |\epsilon_r| \leqslant 2^{-t}$$

$\boxed{17}$

$$\epsilon = 2^{-t}$$

$\boxed{18}$

...die entsprechenden Maschinenoperationen, d.h. die Anwendung der jeweiligen Operation auf Zahlen im normierten Gleitpunkzahlenformat nach Def. 1.2

$\boxed{19}$

I) Verknüpfung der Maschinenzahlen mit höherer (ausreichend hoher) Genauigkeit
II) Runden des Ergebnisses auf eine Maschinenzahl

$\boxed{20}$

$$r \circ_{\mathbb{M}} s := rd(r \circ s)$$

$$
\begin{aligned}
r +_{\mathbb{M}} s = (1,11)_2 \cdot 2^0 +_{\mathbb{M}} (1,10)_2 \cdot 2^2 &= (111)_2 \cdot 2^{-2} + (1,10)_2 \cdot 2^{-2} \\
&= (1000,10)_2 \cdot 2^{-2} \\
&= (100010)_2 \cdot 2^1 \\
&= (1,00)_2 \cdot 2^1 = (2)_{10}
\end{aligned}
$$

21 wohingegen das exakte Ergebnis $r + s = \frac{7}{4} + \frac{3}{8} = \frac{17}{8}$ ist.
Der absolute Rundengsfehler ist also

$$
f_{rd} = (r +_{\mathbb{M}} s) - (r + s) = 2 - \frac{17}{8} = -\frac{1}{8}
$$

und der relative Rundungsfehler ist

$$
\begin{aligned}
|f_{rel}| &= |\frac{(1 +_{\mathbb{M}} s) - (r + s)}{r + s}| \\
&= \frac{\frac{1}{8}}{\frac{17}{8}} \\
&= \frac{1}{17} \\
&= 0,0588... \approx 5,88\%
\end{aligned}
$$

Das ist relativ gut, denn der maximale Rundungsfehler bei einer 3-stelligen Mantisse ist $\epsilon = 2^{-3} = 12,5\%$.

$$
r \circ_{\mathbb{M}} s = rd(r \circ s) = (r \circ s) \cdot (1 + \epsilon_0)
$$

23 wobei der relative Fehler ϵ_0 der Gleitpunktoperation wegen Def. 1.10 stets durh die Maschinengenauigkeit beschränkt ist,

$$
\epsilon_0 := \frac{(r \circ_{\mathbb{M}} s) - (r \circ s)}{r \circ s} = \frac{rd(r \circ s) - (r \circ s)}{r \circ s} \leqslant \epsilon
$$

$\boxed{24}$

$$\begin{aligned}\tilde{y} =& \tilde{x} +_{\mathbb{M}} c \\ &= (\tilde{x} + c) \cdot (1 + \epsilon_2) \\ &= ((a +_{\mathbb{M}} b) + c) \cdot (1 + \epsilon_2) \\ &= ((a + b) \cdot (1 + \epsilon_1) + c) \cdot (1 + \epsilon_2) \\ &= a + b + c + (a + b) \cdot \epsilon_1 + (a + b + c) \cdot \epsilon_2 + (a + b) \cdot \epsilon_1 \epsilon_2\end{aligned}$$

$\boxed{25}$

$$\tilde{y} \doteq a + b + c + (a + b) \cdot \epsilon_1 + (a + b + c) \cdot \epsilon_2$$

$\boxed{26}$

$$\begin{aligned}f_{rel}(y) = \frac{\tilde{y} - y}{y} &= \frac{(a + b) \cdot \epsilon_1 + (a + b + c) \cdot \epsilon_2}{a + b + c} \\ &= \frac{a + b}{a + b + c} \cdot \epsilon_1 + \epsilon_2\end{aligned}$$

$\boxed{27}$

$$\begin{aligned}|f_{rel}(y)| &= |\frac{a + b}{a + b + c} \cdot \epsilon_1 + \epsilon_2| \\ &\overset{(D.U.G)}{\leqslant} |\frac{a + b}{a + b + c}| \cdot |\epsilon_1| + |\epsilon_2|\end{aligned}$$

$\boxed{28}$

$$|f_{rel}(y)| \leqslant (1 + |\frac{a + b}{a + b + c}|) \cdot \epsilon = (a + \frac{1}{|1 + \frac{c}{a+b}|}) \cdot \epsilon$$

$$c \approx -(a+b)$$

29 ist. Denn für $c \to -(a+b)$ ist $\frac{|a+b|}{|a+b+c|} \to \infty$ und damit wird auch die obere Schranke von $|f_{rel}(y)|$ beliebig (unendlich) groß. In diesem Fall spricht man von **Auslöschung**

30-36

$$y + \delta_y = f(x+\delta_x) = f(x) + f'(x)\delta_x + O(\delta_x^2)$$

Unter Vernachlässigung der Terme höherer Ordnung gilt also:

37 $$\delta_y \doteq f'(x) \cdot \delta_x$$

Die Verstärkung des relativen Rundungsfehlers ϵ_y des Resultats y ergibt sich dann für $x, y \neq 0$:

$$\epsilon_y = f_{rel}(y) = \frac{\delta_y}{y} \doteq \frac{f'(x) \cdot \delta_x}{y} = \frac{x\dot{f}'(x)}{y} \cdot \frac{\delta_x}{x} = \frac{x \cdot f'(x)}{y} \cdot \epsilon_x \qquad (1.12)$$

aus dem relativen Rundungsfehler ϵ_x der Eingabe x.

... aus dem Verstärkungsfaktor

38 $$K_f(x) := |\frac{x \cdot f'(x)}{f(x)}|$$

zwschen den relativen Rundungsfehlern aus (1.12)

2 Lineare Gleichungssysteme

40

$$\begin{aligned} 10x_1 + 7x_2 + 0x_3 &= 7 \\ 2,5x_2 + 5x_3 &= 2,5 \\ 6,2x_3 &= 6,2 \end{aligned}$$

... oder in Matrixschreibweise:

$$\begin{pmatrix} 10 & -7 & 0 \\ 0 & 2,5 & 5 \\ 0 & 0 & 6,2 \end{pmatrix} \cdot \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 7 \\ 2,5 \\ 6,2 \end{pmatrix}$$

41

$$\begin{aligned} x_3 &= \frac{6,2}{6,2} = 1 \\ x_2 &= \frac{2,5 - 5x_3}{2,5} = \frac{2,4 - 5 \cdot 1}{2,5} = -1 \\ x_1 &= \frac{7 - 0x_2 + 7x_2}{10} = \frac{7 - 0 - 7}{10} = 0 \end{aligned}$$

Somit resultiert der Lösungsvektor $\begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 0 \\ -1 \\ 1 \end{pmatrix}$

42

I) Berechnung $x_n = \frac{b_n}{a_n n}$

II) Schrittweise Berechnung :
Für $i = n-1, n-2, ..., 3, 2, 1$ ist $x_i = \frac{b_i - \sum_{j=i+1}^{n} a_{ij} \cdot x_j}{a_{ii}}$

43

$$\begin{pmatrix} a_{11} & a_{12} & a1n \\ a_{21} & a_{22} & a2n \\ \vdots & & \\ a_{n1} & a_{n2} & a_{nn} \end{pmatrix} \cdot \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{pmatrix}$$

44

$$\begin{pmatrix} 10 & -7 & 0 \\ -3 & 2 & 6 \\ 5 & -1 & 5 \end{pmatrix} \cdot \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 7 \\ 4 \\ 6 \end{pmatrix}$$

45

$$\begin{pmatrix} 10 & -7 & 0 \\ 0 & -0.1 & 6 \\ 5 & -1 & 5 \end{pmatrix} \cdot \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 7 \\ 6,1 \\ 6 \end{pmatrix}$$

46

$$\begin{pmatrix} 10 & -7 & 0 \\ 0 & -0.1 & 6 \\ 0 & 2,5 & 5 \end{pmatrix} \cdot \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 7 \\ 6,1 \\ 2,5 \end{pmatrix}$$

47

$$\begin{pmatrix} 10 & -7 & 0 \\ 0 & -0.1 & 6 \\ 0 & 0 & 155 \end{pmatrix} \cdot \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 7 \\ 6,1 \\ 155 \end{pmatrix}$$

$\boxed{48}$

$$x_3 = \frac{155}{155} = 1$$
$$x_2 = \frac{6,1 - 6 \cdot 1}{-0,1} = -1$$
$$x_1 = \frac{7 - (-7) \cdot (-1) - 0 \cdot 1}{10} = 0$$

$\boxed{49}$

$$\begin{pmatrix} 10 & -7 & 0 \\ 0 & 0 & 6 \\ 0 & 2,5 & 5 \end{pmatrix} \cdot \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 7 \\ 6,1 \\ 2,5 \end{pmatrix}$$

$\boxed{50}$

$$\begin{pmatrix} 10 & -7 & 0 \\ 0 & 2,5 & 5 \\ 0 & -0,1 & 6 \end{pmatrix} \cdot \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 7 \\ 2,5 \\ 6,1 \end{pmatrix}$$

$\boxed{51}$

$$\begin{pmatrix} 10 & -7 & 0 \\ 0 & 2,5 & 5 \\ 0 & 0 & 6,2 \end{pmatrix} \cdot \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 7 \\ 2,5 \\ 6,2 \end{pmatrix}$$

$\boxed{52}$

Für eine $k \times n$ Matrix A und eine $n \times m$ Matrix B

$$A = \begin{pmatrix} a_{11} & \dots & a_{1n} \\ \vdots & & \vdots \\ a_{k1} & \dots & a_{kn} \end{pmatrix} \text{ und } B = \begin{pmatrix} b_{11} & \dots & b_{1m} \\ \vdots & & \vdots \\ b_{n1} & \dots & b_{bm} \end{pmatrix}$$

ergibt sich das <u>Matrixprodukt</u> $A \cdot B$ durch die $k \times m$ Matrix

$$A \cdot B = \begin{pmatrix} \sum_{j=1}^{n} a_{1j} \cdot b_{j1} & \dots & \sum_{j=1}^{n} a_{1j} \cdot b_{jm} \\ \vdots & & \vdots \\ \sum_{j=1}^{n} a_{kj} \cdot b_{j1} & \dots & \sum_{j=1}^{n} a_{kj} \cdot b_{jm} \end{pmatrix}$$

$\boxed{53}$

$$(AB)_{rs} = \sum_{j=1}^{n} a_{rj} b_{js}$$

$\boxed{54}$

$$A \cdot (B \cdot C) = (A \cdot B) \cdot C$$
$$A \cdot (B + C) = A \cdot B + A \cdot C$$

$\boxed{55}$

$$C = x^T \cdot y = (x_1, ..., x_n) \cdot \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix} = \sum_{j=1}^{n} x_j \cdot y_j \quad \in \mathbb{R}$$